故障模型

术语定义

在分布式系统中,理解故障模型的相关术语是至关重要的,这些术语帮助我们分类和处理不同类型的系统错误。以下是关键术语的定义:

• Fault (缺陷)

- · **定义**: 系统中的缺陷或漏洞, 不一定会导致系统出故障。
- **说明**: Fault是潜在的错误,存在于系统的硬件或软件中。例如,硬件上的物理损坏或软件代码中的漏洞。

• Error (错误)

- 。 **定义**: 系统的实际状态与预期状态之间的差异。
- o **说明**: 当Fault被激活时,系统进入一个意外状态,这就是Error。Error并不一定会导致 Failure。如果系统的异常情况(如异常抛出)能够被捕获并处理,则系统仍然可以按照规约运 行。

• Failure (故障)

- 。 **定义**: 系统的实际行为与其规范或预期行为不一致。
- o **说明**: Failure是最严重的情况,表示系统的Error没有被处理,从而导致系统无法正常工作。 例如,未处理的错误导致系统崩溃。

• 故障传播路径

- 描述: Fault → Error → Failure
- 。 **说明**:这是故障传播的典型路径。一个系统中的Fault可能会导致Error,而Error如果没有被处理或被掩盖,则会导致系统Failure。

故障分类

在分布式系统中,根据故障的性质和影响,可以将其分类为以下几类:

• 瞬态性故障 (Transient)

- · **定义**: 临时性故障, 短暂存在且可能不会重复出现。
- 。 **示例**: 网络抖动导致的短暂连接中断。

• 间歇性故障 (Intermittent)

- 。 **定义**:偶尔发生的故障,间隔不定期出现。
- 示例: 硬件接触不良导致的间歇性连接问题。

永久性故障 (Permanent)

- 。 **定义**: 持续存在的故障, 不会自动恢复。
- · **示例**: 硬盘故障导致的数据不可访问。

• 进程和通信通道故障

- 遗漏故障 (Omission Failure)
 - **定义**:进程或通信通道未完成其应执行的操作。
 - 分类:
 - 崩溃故障 (Crash Failure): 进程停止并一直停止。

- **停止故障** (Fail-Stop Failure): 进程停止并可以被检测到。
- **通道遗漏故障** (Channel Omission Failure): 消息未能从发送方传递到接收方。
- **发送遗漏故障** (Send Omission Failure): 消息未进入发送方的发送缓冲区。
- 接收遗漏故障 (Receive Omission Failure): 消息到达接收方的接收缓冲区,但未被接收方处理。
- 随机故障 (Arbitrary/Byzantine Failure)
 - **定义**:进程或通道表现出不可预测的、随机的行为,包括发送错误信息或不执行任何操作。
 - **示例**:恶意节点故意发送错误信息以破坏系统一致性。
- 时序故障 (Timing Failure)
 - 定义: 系统的时间行为不符合预期。
 - 分类:
 - **时钟故障** (Clock Failure): 进程的本地时钟与实际时间偏离。
 - 进程性能故障 (Process Performance Failure): 进程执行时间超过预期。
 - 通道性能故障 (Channel Performance Failure): 消息传递时间超过预定范围。

可靠通信

在分布式系统中,可靠通信是确保系统一致性和正确性的关键。特别是在组播通信中,消息的可靠传递是非常重要的。以下将详细介绍可靠通信的相关内容,包括定义与需求、所面临的挑战以及具体的解决 思路和算法。

定义与需求

可靠通信涉及两个主要属性:有效性和完整性。

- **有效性** (Validity, Liveness): 在外发消息缓冲区的任何消息最终能被传递到接收消息缓冲区。这意味着发送的消息不会被丢失,而是一定会到达目的地。
- 完整性 (Integrity, Safety):接收到的消息与发送的消息一致,没有消息被传递两次。这意味着消息不会被篡改或重复传递,确保消息的内容和顺序正确。

挑战

在实现可靠组播通信时,面临的主要挑战是**遗漏故障** (Omission Failure)。

- 组播消息在传输过程中可能会因为缓冲区溢出、网络故障或其他原因而丢失。
- 组播路由器可能会出现故障,导致消息无法到达所有预期的接收者。

这些故障会导致消息未能被正确传递, 进而影响系统的一致性和可靠性。

实现方法

为了解决上述挑战,可以使用以下两种主要方法:基本组播原语 (B-multicast) 和可靠组播 (R-multicast)。

基本组播原语 (B-multicast) 和 可靠组播 (R-multicast) 是实现可靠组播通信的两个重要技术。以下是这两种方法的详细解释和实现算法。

基本组播原语 (B-multicast)

基本组播原语 (B-multicast) 确保在没有进程崩溃的情况下,消息能够被所有目标进程接收到。

算法实现:

1. 发送阶段:

。 当一个进程 p 想要发送消息 m 到组 g 中的所有进程时,它会对每个目标进程 p∈g 调用 send(p, m) 方法。这是一个可靠的一对一发送操作。

2. 接收阶段:

○ 当进程 p 接收到消息 m 时,它调用 B-deliver(m) 方法来处理该消息。

```
To B-multicast(g, m):
  for each process p ∈ g:
    send(p, m) // send is a reliable one-to-one operation

On receive(m) at p:
    B-deliver(m) at p
```

可靠组播 (R-multicast)

可靠组播 (R-multicast) 在基本组播原语 (B-multicast) 的基础上,增加了消息的确认和重传机制,以确保消息在进程间的一致传递。

算法实现:

1. 初始化:

○ 每个进程初始化一个已接收消息的集合 Received := {}。

2. 发送阶段:

o 当一个进程 p 想要发送消息 m 到组 g 时,它会调用 B-multicast(g, m) 方法。这保证消息会被组中所有进程接收到。

3. 接收阶段:

o 当进程 q 接收到消息 m 时,若消息 m 不在 Received 集合中,它会将消息 mmm 添加到 Received 集合,并调用 R-deliver(m) 方法处理该消息。如果 q 不是发送者 p,它会再次 调用 B-multicast(g, m) 将消息转发给组中的其他进程。

```
On initialization:
   Received := {}

For process p to R-multicast message m to group g:
   B-multicast(g, m)

On B-deliver(m) at process q with g = group(m):
   if (m \notin Received):
      Received := Received \cup {m}
      if (q \notin p):
        B-multicast(g, m)
      R-deliver(m)
```

协定问题

共识算法

在分布式系统中,共识是确保系统中各个节点达成一致性的重要机制。无论是为了进行事务处理、选举领导者、实现互斥还是进行数据复制,共识算法都是不可或缺的。具体来说,共识的需求源于以下几个方面:

- 1. **事务处理**:在分布式数据库中,需要确保多个节点对某个事务的提交或回滚达成一致,以维护数据的一致性。
- 2. 领导者选举: 在分布式系统中,需要选举一个领导者来协调系统的操作,例如分布式锁服务。
- 3. **互斥**:确保在分布式系统中,同一时间只有一个节点可以访问共享资源,以避免冲突和不一致。
- 4. 数据复制: 在分布式存储系统中,需要确保所有副本的数据一致,以保证数据的可用性和可靠性。

达成共识的基本思路包括以下几个关键步骤:

- 1. 提出值:每个进程根据其本地状态提出一个值。
- 2. 交換值: 讲程之间相互通信, 交换各自提出的值。
- 3. 决定值:通过一定的算法,每个进程根据交换到的值作出决定。
- 4. 达成一致: 所有正确的进程最终达成一致的决定值。

共识算法需要满足以下三个性质:

- 终止性: 每个正确的进程最终会作出决定。
- 协定性: 所有正确的进程的决定值都相同。
- 完整性: 如果所有正确的进程都提出相同的值, 那么他们的决定值也是这个值。

Paxos

Paxos算法由Leslie Lamport提出,是为了在分布式系统中,即使存在节点故障和网络不可靠的情况下,也能达成一致性。Paxos的设计思想是通过一系列的提案和投票过程,确保系统中的大多数节点能够同意一个提案,从而达成共识。

算法步骤

Paxos算法主要分为三个阶段: Prepare、Promise和Accept/Propose。

1. Prepare阶段

- Proposer 选择一个提案编号 n , 并向多数 Acceptor 发送 Prepare(n) 请求。
- o Acceptor 收到 Prepare(n) 请求后,如果 n 大于它已经响应过的所有提案编号,则承诺不再接受比 n 小的提案,并将它已经接受的最高编号的提案(如果有)返回给 Proposer。

2. Promise阶段

○ **Acceptor** 向 **Proposer** 承诺不再接受编号小于 n 的提案,并发送 Promise(n, v)响应,其中 v 是它已经接受的最高编号的提案的值。

3. Propose阶段

Proposer 收到多数 Acceptor 的 Promise 响应后,选择值 v 为之前收到的所有提案中编号最高的提案的值,如果没有收到任何提案,则可以自由选择一个值 v。然后向多数 Acceptor发送 Propose(n, v)请求。

4. Accept阶段

o **Acceptor** 收到 Propose(n, v) 请求后,如果没有违反之前的承诺(即没有接受编号大于 n 的提案),则接受提案并将其作为最终提案,并通知 **Learner**。

5. Learn阶段

。 Learner 从多数 Acceptor 处学习到相同的提案值 ▽ ,即达成共识。

Raft

Raft算法是由Diego Ongaro和John Ousterhout提出的,目的是提供一个更易于理解和实现的分布式共识算法。Raft通过明确的角色划分和简单的选举过程,简化了共识的实现,保持了与Paxos相同的强一致性和容错能力。

算法步骤

Raft算法将系统中的节点分为三种角色: Leader、Follower和Candidate,并通过选举、日志复制和安全性机制来实现共识。

1. 选举

- o Follower 等待来自 Leader 的心跳消息,如果在一定时间内没有收到心跳消息,则转换为 Candidate 并发起选举。
- o Candidate 向其他所有节点发送 RequestVote 消息,节点投票给第一个请求投票的候选人。
- o Candidate 收到多数节点的投票后,成为 Leader,并开始发送心跳消息以维持领导地位。

2. 日志复制

- Leader 接收到客户端请求后,将请求作为日志条目添加到本地日志,并向其他 Follower 发送 AppendEntries 消息。
- o Follower 接收到 AppendEntries 消息后, 追加日志条目并返回确认。
- Leader 收到多数节点的确认后,提交日志条目,并将结果返回给客户端。

3. 安全性机制

- Leader 通过心跳消息确保自己仍然是集群的领导者,并确保所有 Follower 的日志与自己一致。
- Follower 如果在选举过程中收到较新的日志条目,则拒绝投票给较旧的候选人,确保日志的一致性。

复杂性

- **时间复杂度**: Raft的选举过程和日志复制过程都需要多个回合的消息传递,时间复杂度通常为O(n)。
- 消息复杂度: Raft的消息复杂度较低,选举过程和日志复制过程的消息数量相对固定。

Raft的优点在于其简洁和易于实现,同时保持了强一致性和容错能力。Raft通过明确的角色划分和简单的 状态转换,简化了共识算法的实现,使其在实际应用中广泛使用。

复杂性

- **时间复杂度**:由于Paxos需要多个回合的消息传递(每个阶段至少一次),其时间复杂度较高,通常为O(n)。
- 消息复杂度:每个阶段都涉及到多个消息的发送和接收,消息复杂度也较高。

Paxos的优点在于其理论上的严格证明和对网络分区的处理能力,但由于其实现的复杂性和高通信开销,在实际应用中较难实现。

拜占庭将军问题

拜占庭将军问题(Byzantine Generals Problem)是分布式系统中经典的共识问题之一,旨在解决在存在恶意节点(即拜占庭节点)的情况下如何达成一致性的问题。这个问题由Leslie Lamport在1982年提出,强调即使系统中有部分节点故意发送虚假信息,系统中的其他节点也要能够达成一致。

问题定义

拜占庭将军问题的核心是在一个分布式系统中,如何确保所有忠诚的节点能够达成一致的决定,即使某些节点可能是恶意的或不可靠的。具体来说,这个问题描述了如下场景:

- 有 nnn 个将军(节点), 其中最多有 mmm 个将军可能是叛徒(恶意节点)。
- 这些将军必须就一个共同的决定达成一致,例如攻击或撤退。
- 恶意将军可以发送虚假信息,以试图混淆忠诚将军的判断。

性质

拜占庭将军问题需要满足以下三个性质:

- 1. 终止性: 所有忠诚的将军最终都会做出决定。
- 2. 一致性: 所有忠诚的将军做出的决定是相同的。
- 3. 完整性: 如果将军是忠诚的, 那么其他所有忠诚的将军必须选择该将军的决定。

PBFT

PBFT (Practical Byzantine Fault Tolerance) 是拜占庭容错问题的一种实际可行的解决方案,由Miguel Castro和Barbara Liskov在1999年提出。PBFT能够在系统中有 m 个拜占庭节点时,仍然保证系统达成一致,需要总节点数 n≥3m+1。

算法步骤

PBFT算法分为三个主要阶段: 预备 (Pre-prepare)、准备 (Prepare) 和提交 (Commit)。

1. Pre-prepare阶段

o **Primary** (主要节点)接收客户端请求并将其广播给所有其他节点(包括自己),生成预备消息 Pre-prepare.

2. Prepare阶段

- o 每个节点收到 Pre-prepare 消息后,向所有其他节点广播 Prepare 消息。
- o 节点在收到至少 2f 个 Prepare 消息后 (包括自己的 Prepare 消息), 进入下一阶段。

3. Commit阶段

- o 每个节点广播 Commit 消息。
- 。 节点在收到至少 2f+1 个 Commit 消息后, 执行客户端请求并返回结果。

OM(m)

OM(m) 是一个递归算法,用来解决拜占庭将军问题。

算法步骤

1. OM(0)算法

- 。 将军直接将自己的命令发送给所有副将。
- 。 每个副将使用自己收到的命令(如果没有收到则使用默认值)。

2. OM(m)算法

- 。 司令将自己的命令发送给所有副将。
- 。 每个副将作为新司令,使用OM(m-1)算法将其收到的命令发送给其他副将。
- 每个副将根据接收到的命令集,使用多数投票决定最终命令。

分布式恢复

• 后向恢复

o **定义**:将系统从当前错误状态恢复到先前正确状态。

o 方法: 重传消息、检查点、消息日志。

• 挑战: 高成本、恢复循环、某些状态不可回滚。

• 前向恢复

o **定义**:将系统带入一个新的正确状态,从该状态继续执行。

o **方法**:擦除修正、自稳定算法。

• 挑战: 预知可能出现的错误。

• 检查点算法

- 同步检查点 (协调检查点)
- 异步检查点 (独立检查点)

• 消息日志

- 。 类型
 - 悲观消息日志
 - 乐观消息日志
- · 恢复方法:通过重新执行日志中记录的消息恢复进程状态。

• 一致性判断

o **定义**:全局状态的一致性意味着所有进程的本地状态与全局状态一致。

• 判断方法: 利用向量时钟和依赖矩阵。