

# 引言

## 双视视觉的基本概念

双视视觉 (Stereo Vision) 是一种通过分析两个或多个相机拍摄的图像来获取三维场景信息的技术。它模仿人类的双眼视觉系统，通过计算不同视点下图像的差异来恢复场景的深度信息。双视视觉的基本思想是，通过比较来自两个不同位置的相机拍摄的图像，找到图像中对应的点，并利用几何关系计算这些点的三维坐标。

双视视觉在许多领域有着广泛的应用，包括：

- 机器人导航**：帮助机器人在环境中定位和避障。
- 自动驾驶**：用于感知车辆周围的三维环境，识别障碍物和道路标志。
- 三维重建**：创建物体或场景的三维模型，用于虚拟现实、考古学和医学成像等领域。

## 深度感知的问题

在双视视觉中，深度感知是指从二维图像中提取三维信息的过程。主要问题在于如何从两个视角的图像中找到同一个场景点的对应关系，并通过几何关系计算该点的深度。这一过程涉及以下几个关键步骤：

- 特征提取**：从两幅图像中提取特征点，例如角点、边缘点或其他显著特征。
- 特征匹配**：在两幅图像中找到对应的特征点，这些特征点代表同一个物理点。
- 几何计算**：利用相机的内外参数和图像点之间的对应关系，计算三维点的深度信息。

深度感知的难点在于：

- 匹配准确性**：找到两幅图像中准确的对应点是一个挑战，尤其是在存在遮挡、光照变化和视角变化的情况下。
- 噪声影响**：图像中的噪声和误差会影响匹配的准确性，从而影响深度计算的精度。
- 计算复杂度**：大规模图像匹配和深度计算需要大量的计算资源。

## 图像与射线

### 图像上的点与物理世界中的射线关系

在相机成像过程中，每个图像点都对应于物理世界中的一条射线。因相机投影的固有属性，一个二维图像点并不能直接提供三维信息，它只能描述该点可能位于的射线方向。具体而言，图像点  $\mathbf{x}$  是通过相机投影矩阵  $K$  将三维点  $\mathbf{X}$  投影到图像平面上的结果，即  $\mathbf{x} = K\mathbf{X}$ 。

相机的投影矩阵  $K$  包含了相机的内参信息，如焦距  $f$ 、光心位置  $(c_x, c_y)$  和畸变参数等。通过逆投影，可以将图像点  $\mathbf{x}$  映射回空间中的射线： $\mathbf{r} = K^{-1}\mathbf{x}$  其中， $\mathbf{r}$  是射线的方向向量。

### 多视图中的射线交点

当使用两个或多个相机时，每个相机拍摄的图像中同一个物理点在不同视角下的位置不同。通过计算这些位置对应的射线的交点，可以确定该点在三维空间中的坐标。具体而言，假设两个相机的投影矩阵分别为  $K$  和  $K'$ ，则图像点  $\mathbf{x}$  和  $\mathbf{x}'$  在物理空间中的重投影线分别为： $\mathbf{r} = K^{-1}\mathbf{x}$ ， $\mathbf{r}' = K'^{-1}\mathbf{x}'$

这些重投影线的交点即为物理点的三维坐标  $\mathbf{X}$ 。这种方法称为三角化，通过求解射线交点来恢复三维信息。假设两条射线相交于点  $\mathbf{X}$ ，则： $\mathbf{X} = \mathbf{r} \cap \mathbf{r}'$

在实际操作中，由于图像中的噪声和测量误差，两条射线可能并不会完全相交，而是以最小距离相交。因此，需要通过最小二乘法等优化方法来计算近似的交点，从而得到物理点的三维坐标。

# 三角化

## 三角化的基本概念

三角化（Triangulation）是从两个或多个视图的图像中恢复三维点坐标的过程。它利用相机的投影矩阵和图像点的坐标，通过几何关系计算出三维空间中点的位置。三角化是双视视觉的核心技术，广泛应用于三维重建、机器人导航和自动驾驶等领域。

## 三角化的数学公式与计算方法

三角化的基本思想是通过两幅图像中的对应点以及相机的投影矩阵，确定三维点的坐标。假设有两个相机，其投影矩阵分别为  $P_1$  和  $P_2$ ，在这两个相机中拍摄的图像中，某个三维点  $X$  对应的图像点分别为  $x_1$  和  $x_2$ 。

相机投影模型可以表示为： $x_1 = P_1 X, x_2 = P_2 X$ ：

其中， $x_1$  和  $x_2$  是齐次坐标表示的图像点， $X$  是齐次坐标表示的三维点。将上述投影模型展开，可以得到以下方程组：

$$x_1 = \begin{bmatrix} u_1 \\ v_1 \\ 1 \end{bmatrix}$$
$$P_1 = \begin{bmatrix} p_{11} & p_{12} & p_{13} & p_{14} \\ p_{21} & p_{22} & p_{23} & p_{24} \\ p_{31} & p_{32} & p_{33} & p_{34} \end{bmatrix}$$
$$u_1 = \frac{p_{11}X + p_{12}Y + p_{13}Z + p_{14}}{p_{31}X + p_{32}Y + p_{33}Z + p_{34}}$$
$$v_1 = \frac{p_{21}X + p_{22}Y + p_{23}Z + p_{24}}{p_{31}X + p_{32}Y + p_{33}Z + p_{34}}$$

对于图像点  $x_2$  和投影矩阵  $P_2$ ，类似的方程可以写为：

$$x_2 = \begin{bmatrix} u_2 \\ v_2 \\ 1 \end{bmatrix}$$
$$P_2 = \begin{bmatrix} p'_{11} & p'_{12} & p'_{13} & p'_{14} \\ p'_{21} & p'_{22} & p'_{23} & p'_{24} \\ p'_{31} & p'_{32} & p'_{33} & p'_{34} \end{bmatrix}$$
$$u_2 = \frac{p'_{11}X + p'_{12}Y + p'_{13}Z + p'_{14}}{p'_{31}X + p'_{32}Y + p'_{33}Z + p'_{34}}$$
$$v_2 = \frac{p'_{21}X + p'_{22}Y + p'_{23}Z + p'_{24}}{p'_{31}X + p'_{32}Y + p'_{33}Z + p'_{34}}$$

通过这两组方程，可以建立一个超定线性方程组，求解三维点  $X$  的坐标。为了方便计算，通常将方程组转化为矩阵形式，并使用线性代数方法求解。矩阵形式如下： $AX = 0$

其中，矩阵  $A$  是由  $P_1$  和  $P_2$  以及  $x_1$  和  $x_2$  组成的超定矩阵， $X$  是待求解的三维点坐标向量。

## 噪声对三角化的影响及近似解

在实际应用中，由于图像噪声和测量误差，方程组  $AX = 0$  可能没有精确解。为了得到一个尽可能接近真实值的近似解，可以使用最小二乘法（Least Squares Method）来求解。

最小二乘法的目标是找到一个解  $X$ ，使得误差  $AX$  的平方和最小。具体步骤如下：

1. **构建误差函数**：构建误差函数  $E(X) = \|AX\|^2$ 。

2. **求解最小值**：通过对误差函数求导，并设导数为零，找到误差函数的最小值。

实际求解时，通常使用奇异值分解（SVD, Singular Value Decomposition）的方法，将矩阵  $A$  分解为  $A = U\Sigma V^T$ ，其中  $U$  和  $V$  是正交矩阵， $\Sigma$  是对角矩阵。最小奇异值对应的奇异向量即为方程组的近似解。

## 重投影与叉乘

### 重投影线的计算

重投影线是指从图像平面上的点通过相机投影矩阵映射回三维空间中的射线。在双视视觉中，每个图像点对应的重投影线在三维空间中形成了一条射线，通过计算这些射线的交点，可以确定三维点的位置。

假设图像点  $x$  在相机的投影矩阵  $P$  下，其对应的重投影线可以表示为： $l = P^{-1}x = P^{-1}x$

### 叉乘在重投影计算中的应用

叉乘是计算几何中的一个重要工具，在重投影线的计算中也有广泛应用。叉乘的定义是两个向量的乘积，其结果是一个垂直于这两个向量的向量。在重投影线的计算中，叉乘可以用于求解射线之间的交点。

具体而言，对于两个方向向量  $a$  和  $b$ ，它们的叉乘  $a \times b$  得到一个垂直于  $a$  和  $b$  的向量。这个性质在求解重投影线的交点时非常有用，因为两条射线的交点必须满足这个垂直条件。

### 重投影线的线性组合与求解

重投影线的计算可以通过线性组合的方法求解。假设两个相机的投影矩阵分别为  $P_1$  和  $P_2$ ，图像点分别为  $x_1$  和  $x_2$ 。通过投影矩阵的逆，可以计算出图像点的重投影线： $l_1 = P_1^{-1}x_1, l_2 = P_2^{-1}x_2$

重投影线的交点可以通过解如下的线性方程组来求解： $l_1 \times l_2 = 0$

这个方程组可以转化为矩阵形式，通过线性代数的方法求解。假设  $l_1$  和  $l_2$  的方向向量分别为  $r_1$  和  $r_2$ ，则它们的叉乘为：

$$r_1 \times r_2 = \begin{vmatrix} \mathbf{i} & \mathbf{j} & \mathbf{k} \\ r_{1x} & r_{1y} & r_{1z} \\ r_{2x} & r_{2y} & r_{2z} \end{vmatrix} = (r_{1y}r_{2z} - r_{1z}r_{2y}, r_{1z}r_{2x} - r_{1x}r_{2z}, r_{1x}r_{2y} - r_{1y}r_{2x})$$

解得的向量即为三维点的坐标。

通过这些计算和方法，双视视觉可以从二维图像中精确地恢复三维场景的深度信息和结构。这些技术在计算机视觉中有着广泛的应用，为自动驾驶、机器人导航和虚拟现实等领域提供了重要的技术支持。

## 最小二乘法与奇异值分解 (SVD)

### 超定齐次方程组的最小二乘解法

在双视视觉中，三角化的问题通常转化为求解超定齐次方程组的问题。超定齐次方程组是指方程的数量多于未知数的方程组，形式为：

$$AX = 0$$

其中，矩阵  $A$  是已知的，向量  $X$  是待求解的未知向量。在实际应用中，由于图像中的噪声和测量误差，方程组通常没有精确的解，需要通过最小二乘法求解一个近似解。

最小二乘法的目标是找到一个向量  $X$ ，使得误差  $AX$  的平方和最小，即：

$$\min_{\mathbf{X}} \|A\mathbf{X}\|^2$$

为了求解这个问题，可以将其转化为求解矩阵  $A$  的最小奇异值对应的右奇异向量的问题。这样可以找到一个使得误差最小的近似解。

## 通过SVD求解最小奇异值对应的右奇异向量

奇异值分解（SVD, Singular Value Decomposition）是一种常用的矩阵分解方法，将矩阵  $A$  分解为三个矩阵的乘积：

$$A = U\Sigma V^T$$

其中， $U$  和  $V$  是正交矩阵， $\Sigma$  是对角矩阵，对角线上是矩阵  $A$  的奇异值。奇异值按降序排列，奇异值越小，对应的向量越接近于零空间。

具体来说，矩阵  $AAA$  的奇异值分解步骤如下：

- 计算矩阵  $A^T A$** ：这是一个对称正定矩阵。
- 求解  $A^T A$  的特征值和特征向量**：特征值的平方根即为矩阵  $A$  的奇异值，对应的特征向量构成矩阵  $V$  的列。
- 构造对角矩阵  $\Sigma$** ：将奇异值按降序排列，构成对角矩阵  $\Sigma$ 。
- 计算矩阵  $U$** ：通过  $U = AV\Sigma^{-1}$  计算得到。

在求解最小二乘问题时，奇异值分解的关键步骤是找到矩阵  $A$  的最小奇异值对应的右奇异向量。具体过程如下：

- 对矩阵  $AAA$  进行奇异值分解**：得到  $A = U\Sigma V^T$ 。
- 找到最小奇异值  $\sigma_{min}$** ： $\Sigma$  的对角元素即为奇异值，最小奇异值对应的特征向量是  $V$  的最后一列（即最小奇异值对应的右奇异向量）。
- 求解右奇异向量**：最小奇异值对应的右奇异向量  $v_{min}$  即为我们所求的  $\mathbf{X}$  的最小二乘解。

通过SVD求解最小奇异值对应的右奇异向量的优点在于：

- 稳健性**：SVD对噪声和误差有很好的稳健性，能够提供一个稳定的最小二乘解。
- 精度**：SVD方法能够找到误差最小的解，确保解的精度。

在双视视觉的应用中，使用最小二乘法和SVD求解重投影线的交点，可以有效地恢复三维点的坐标，为进一步的三维重建和深度感知提供可靠的基础。

## 对极几何

### 对极几何的基本概念

对极几何（Epipolar Geometry）描述了同一场景在两个视图之间的几何关系，是双视视觉中非常重要的概念。它定义了在一幅图像中的点在另一幅图像中的对应点的位置约束，通过对极几何，可以减少图像匹配的搜索空间，提高匹配的效率和准确性。

在双视视觉中，有两个相机  $C$  和  $C'$  分别拍摄的两幅图像。假设三维点  $X$  在两幅图像中的对应点为  $x$  和  $x'$ 。对极几何的基本组成部分包括对极点、对极线和对极平面：

- 对极点 (Epipole)**：对极点是另一相机中心在当前图像中的投影。对于相机  $C$ ，其对极点在图像中的投影为  $e$ ，对于相机  $C'$ ，其对极点在图像中的投影为  $e'$ 。
- 对极线 (Epipolar Line)**：对极线是通过对极点的直线。在一幅图像中，对应点  $x$  的所有可能位置都位于通过  $e'$  的对极线上。同样， $x'$  的所有可能位置都位于通过  $e$  的对极线上。
- 对极平面 (Epipolar Plane)**：由三维点  $X$ 、两个相机中心  $C$  和  $C'$  组成的平面称为对极平面。

对极几何的一个重要特性是：图像中的对应点必须满足对极约束，即一个点的对应点必须在对极线上。这大大缩小了对应点搜索的范围，从二维平面缩减到一维直线。

## 本质矩阵与基础矩阵

在对极几何中，本质矩阵（Essential Matrix）和基础矩阵（Fundamental Matrix）是两个重要的数学工具，用于描述两幅图像之间的几何关系。

本质矩阵  $E$  适用于相机内部参数已知情况。它将一个图像中的点映射到另一图像中的对极线。假设有两个相机，其内参矩阵分别为  $K$  和  $K'$ ，外参分别为  $R$  和  $t$ ，则本质矩阵可以表示为： $E = [t]_{\times} R$

其中， $[t]_{\times}$  是平移向量  $t$  的反对称矩阵。对于图像点  $x$  和  $x'$ ，它们满足以下对极约束： $x'^T E x = 0$

基础矩阵  $F$  适用于相机内部参数未知的情况。它也将一个图像中的点映射到另一图像中的对极线。基础矩阵可以通过本质矩阵和相机内参矩阵计算得到： $F = (K')^{-T} E K^{-1}$

对于图像点  $x$  和  $x'$ ，它们也满足类似的对极约束： $x'^T F x = 0$

### 对极约束与对应点的搜索

对极约束是对极几何中最重要的性质之一，它描述了在一个图像中的点在另一图像中的对应点必须位于对极线上。具体来说，如果在图像1中的点的坐标为  $x$ ，则该点在图像2中的位置  $x'$  必须满足以下对极约束： $x'^T F x = 0$

由于对极约束，一个点的对应点的搜索空间从二维平面缩小到一维对极线，大大减少了计算复杂度，提高了匹配效率。对应点的搜索步骤如下：

- 计算对极线**：根据图像1中的点  $x$  和基础矩阵  $F$ ，计算图像2中的对极线  $l'$ ： $l' = Fx$
- 在对极线上搜索**：在图像2中沿对极线  $l'$  搜索点  $x'$ ，找到最匹配的点对。
- 验证对极约束**：确保找到的点对  $x$  和  $x'$  满足对极约束： $x'^T F x = 0$

通过对极约束，双视觉系统能够高效地在两幅图像中找到对应点，实现三维重建和深度感知。

## 基础矩阵的计算与应用

基础矩阵（Fundamental Matrix）是对极几何中的一个关键元素，用于描述两个未标定图像之间的几何关系。基础矩阵不仅定义了对应点在两个图像之间的映射关系，还在多视图匹配和三维重建中有着重要的应用。

### 基础矩阵的定义与性质

基础矩阵  $F$  是一个  $3 \times 3$  的矩阵，用于描述两个视图之间的对极几何关系。对于图像1中的点  $x$  和图像2中的点  $x'$ ，它们满足以下对极约束： $x'^T F x = 0$

其中：

- $x$  和  $x'$  是以齐次坐标表示的图像点。
- $F$  是基础矩阵。

基础矩阵的主要性质包括：

- 秩为2**：基础矩阵是一个秩为2的矩阵，这意味着它有一个零奇异值。
- 对称性**：对于每一对对应点，基础矩阵的约束方程  $x'^T F x = 0$  都成立。
- 不依赖于相机的内参**：基础矩阵只依赖于两个相机的相对姿态（旋转和平移）和外部参数，不依赖于相机的内参矩阵。

# 基础矩阵在多视图匹配中的应用

基础矩阵在多视图匹配中有重要的应用，包括但不限于以下几个方面：

- 减少搜索空间**：基础矩阵定义了对应点必须在对极线上的约束，从而将对应点的搜索空间从二维平面缩减到一维直线，大大提高了匹配效率。
- 三维重建**：基础矩阵为三维重建提供了几何约束，通过多视图的匹配点，可以重建三维点的坐标。
- 运动估计**：基础矩阵包含了相机间的相对运动信息，可以用于估计相机之间的旋转和平移。

## 基础矩阵估计方法

估计基础矩阵的方法主要包括八点法（8-point algorithm）、归一化八点法（Normalized 8-point algorithm）和随机抽样一致性算法（RANSAC）。

- 八点法（8-point algorithm）**：八点法是估计基础矩阵的一种经典方法，具体步骤如下：
  - 收集对应点**：从两幅图像中提取至少8对对应点  $(x_i, x'_i)$ 。
  - 构建线性方程组**：对于每对对应点，构建一个线性方程  $x'^T F x = 0$ 。将所有对应点的方程堆叠起来，得到一个线性方程组  $Af = 0$ ，其中  $A$  是一个  $8 \times 9$  的矩阵， $f$  是基础矩阵  $F$  展开的9维向量。
  - 求解方程组**：通过对  $A$  进行奇异值分解（SVD），找到最小奇异值对应的奇异向量  $f$ ，重新排列成  $3 \times 3$  矩阵，即为基础矩阵  $FFF$ 。
  - 约束条件**：为了确保基础矩阵的秩为2，对  $FFF$  进行约束调整，通过再次进行SVD，将最小奇异值置为0，然后重新构建基础矩阵。
- 归一化八点法（Normalized 8-point algorithm）**：归一化八点法是对传统八点法的改进，通过归一化处理，减少数值计算中的误差，具体步骤如下：
  - 归一化处理**：对图像点进行归一化处理，使其均值为0，方差为1。构造归一化矩阵  $T$  和  $T'$  对应图像点进行变换。
  - 应用八点法**：对归一化后的点应用八点法，得到归一化基础矩阵  $F'$ 。
  - 反归一化**：将归一化基础矩阵反归一化，得到最终的基础矩阵  $F = T'^T F' T$ 。
- 随机抽样一致性算法（RANSAC）**：RANSAC是一种用于从含有大量噪声的数据中估计模型参数的鲁棒算法，具体步骤如下：
  - 随机采样**：从匹配点中随机选择8对点，使用八点法估计基础矩阵。
  - 模型验证**：计算所有点对在当前模型下的对极几何约束误差，根据误差判断模型的好坏，找出内点集合。
  - 迭代优化**：重复上述过程多次，选择内点最多的模型作为最终的基础矩阵。

通过这些方法，可以有效地估计基础矩阵，从而为双视视觉中的多视图匹配、三维重建和运动估计提供坚实的基础。

基础矩阵在计算机视觉中有广泛的应用，主要包括：

- 图像对齐**：利用基础矩阵进行图像对齐和立体矫正，以便更好地进行图像匹配和重建。
- 三维重建**：利用基础矩阵和对应点，通过三角化方法重建三维场景。
- 运动估计**：通过基础矩阵估计相机的相对运动，广泛应用于机器人导航和自动驾驶等领域。

## 特征匹配

特征匹配是双视视觉中的关键步骤，通过在两幅图像中找到相同的物理点的对应特征，可以实现三维重建和深度感知。以下是特征匹配的详细介绍，包括特征匹配的基本方法和基于RANSAC的鲁棒估计。

# 特征匹配的基本方法

特征匹配的基本方法包括特征检测、特征描述和特征匹配三个步骤。

- 特征检测**：特征检测是从图像中提取显著特征点的过程，常用的特征检测算法包括：
  - **Harris角点检测**：基于图像梯度，检测图像中的角点。
  - **SIFT（尺度不变特征变换）**：检测不同尺度下的特征点，具有良好的尺度和旋转不变性。
  - **SURF（加速鲁棒特征）**：类似于SIFT，但计算速度更快。
  - **ORB（快速旋转不变二进制描述子）**：结合FAST角点检测和BRIEF描述子，计算效率高。
- 特征描述**：特征描述是为每个特征点生成一个描述子的过程，这些描述子可以用于特征匹配。常用的特征描述子包括：
  - **SIFT描述子**：基于梯度方向直方图，描述子维度为128。
  - **SURF描述子**：基于Haar小波响应，描述子维度为64。
  - **BRIEF描述子**：基于像素强度比较的二进制描述子，描述子维度可调。
- 特征匹配**：特征匹配是将两幅图像中的特征点进行配对的过程，常用的匹配方法包括：
  - **暴力匹配（Brute-Force Matching）**：计算每个特征描述子之间的距离，选择距离最近的作为匹配对。
  - **FLANN（快速近似最近邻搜索）**：基于最近邻搜索的快速匹配算法，适用于大规模数据集。

## 基于RANSAC的鲁棒估计

在特征匹配过程中，由于噪声和误匹配的存在，需要采用鲁棒估计方法来提高匹配的准确性。RANSAC（随机抽样一致性）是一种常用的鲁棒估计算法，通过迭代优化，去除误匹配，提高模型的准确性。

- RANSAC算法步骤**：
  - **随机采样**：从匹配点集中随机选择一个子集，通常选择最小数量的点来估计模型参数。对于基础矩阵的估计，通常选择8对匹配点。
  - **模型估计**：使用随机选择的子集估计模型参数。例如，使用8对匹配点计算基础矩阵 FFF。
  - **模型验证**：将所有匹配点代入估计的模型，计算每个点对的误差（如对极约束误差）。根据误差大小判断匹配点是否为内点。
  - **迭代优化**：重复上述过程多次，记录每次迭代中的内点集合。最终选择内点最多的模型作为最佳模型。
  - **模型重估计**：使用最佳模型的内点集合重新估计模型参数，以获得更加准确的模型。
- RANSAC算法的优点**：
  - **鲁棒性强**：RANSAC能够有效地处理数据中的噪声和误匹配，找到最优模型参数。
  - **计算效率高**：通过迭代优化，RANSAC能够快速收敛到最优解，适用于大规模数据集。
- RANSAC算法的应用**：
  - **基础矩阵估计**：在双视视觉中，RANSAC常用于基础矩阵的估计，通过剔除误匹配点，提高基础矩阵的估计精度。
  - **单应矩阵估计**：在图像拼接和视图变换中，RANSAC常用于单应矩阵的估计，通过剔除误匹配点，提高单应矩阵的估计精度。

# 立体视觉

立体视觉 (Stereo Vision) 是双视视觉的一种应用，通过使用两台相机拍摄同一场景的两幅图像，恢复场景的三维结构。立体视觉技术广泛应用于计算机视觉、机器人导航、自动驾驶等领域。以下是立体视觉的详细介绍。

## 立体视觉的基本原理

立体视觉的基本原理是通过两台相机拍摄同一场景的不同视角图像，从图像对中提取特征点，进行匹配，并利用几何关系恢复三维点的深度信息。其核心思想是三角测量法 (Triangulation)。

### 1. 相机模型：

- 针孔相机模型：**相机的成像过程可以用针孔模型来描述，其中相机的投影矩阵将三维世界坐标系中的点投影到图像平面上。
- 相机标定：**通过相机标定可以获得相机的内参和外参，内参包括焦距和光心位置，外参包括相机的旋转和平移。

### 2. 双目相机系统：

- 基线：**双目相机系统由两台相机组成，两相机之间的距离称为基线 (Baseline)。
- 视差：**在两幅图像中，同一物体点的水平位移称为视差 (Disparity)。视差与物体的深度成反比，视差越大，物体离相机越近；视差越小，物体离相机越远。

### 3. 三角测量：

- 三角测量原理：**通过已知的相机内外参数和图像点的位置，利用三角测量法计算三维点的坐标。

## 三角化假设与深度计算

三角化是假设已知相机参数和图像之间的点的对应关系，通过几何关系计算三维点的深度。具体步骤如下：

### 1. 视差计算：

- 视差图 (Disparity Map)：**通过匹配左右图像中的特征点，计算每个特征点的视差，得到视差图。
- 匹配代价计算：**常用的匹配代价包括绝对差 (SAD)、平方差 (SSD)、归一化互相关 (NCC) 等。

### 2. 深度计算：深度图 (Depth Map)：

根据视差图计算每个像素点的深度，深度与视差的关系为：  
 $Z = \frac{fB}{d}$  其中， $Z$  是深度， $f$  是相机的焦距， $B$  是基线长度， $d$  是视差。

### 3. 三角测量公式：

- 对于图像中的一个点  $(u, v)$  和对应的视差  $d$ ，其三维坐标  $(X, Y, Z)$ ，可以通过以下公式计算：

$$\begin{aligned}X &= \frac{(u - c_x) \cdot Z}{f} \\Y &= \frac{(v - c_y) \cdot Z}{f} \\Z &= \frac{f \cdot B}{d}\end{aligned}$$

其中， $c_x, c_y$  是图像的光心坐标。

## 视差图与深度图的生成

视差图和深度图是立体视觉中的两个重要输出，分别表示图像中每个像素点的视差和深度信息。



### 1. 视差图的生成：

- **块匹配算法 (Block Matching Algorithm)**：将图像分为若干个小块，计算每个小块在左右图像中的匹配代价，找到匹配块，得到视差图。
- **半全局匹配算法 (SGM, Semi-Global Matching)**：通过在多个路径上累积匹配代价，得到更平滑的视差图。
- **动态规划算法 (DP, Dynamic Programming)**：通过构建匹配代价矩阵，使用动态规划方法找到最优匹配路径，生成视差图。

### 2. 深度图的生成：

- **视差到深度的转换**：根据视差图，使用三角测量公式将视差转换为深度，得到深度图。
- **后处理**：对深度图进行滤波和平滑处理，去除噪声和误匹配，提高深度图的质量。

### 3. 立体匹配优化：

- **多视图立体匹配**：利用多幅图像进行立体匹配，得到更准确的视差和深度信息。
- **深度学习方法**：使用卷积神经网络 (CNN) 和生成对抗网络 (GAN) 等深度学习方法进行立体匹配，显著提高视差和深度图的精度。

## 运动恢复结构 (Structure from Motion, SfM)

运动恢复结构 (Structure from Motion, SfM) 是指从多幅图像中恢复三维场景结构和相机运动的技术。SfM广泛应用于计算机视觉、三维重建和图像处理等领域。以下是关于SfM的详细介绍。

### SfM的基本概念

运动恢复结构的核心思想是通过分析多幅图像中的特征点，估计出相机在不同时间点的位置和姿态，同时恢复出场景中三维点的坐标。其基本过程包括以下几个步骤：

- 特征点检测和匹配**：在多幅图像中检测显著的特征点（如SIFT、SURF等），并对这些特征点进行匹配，找出不同图像中的对应点。
- 初始相机位姿估计**：选择两幅图像，利用八点法或本质矩阵估计两幅图像之间的相对位姿。
- 三维点重建**：利用特征点的匹配信息，通过三角测量法恢复出对应特征点的三维坐标。
- 多视图扩展**：将更多的图像加入到重建过程中，不断估计新的相机位姿和新增特征点的三维坐标。
- 优化调整**：通过全局优化（如光束平差法）调整所有相机位姿和三维点坐标，使得重建结果更加精确。

### SfM的计算方法

SfM的计算方法可以分为线性方法和非线性方法两大类。线性方法包括八点法、五点法等，而非线性方法主要包括光束平差法 (Bundle Adjustment, BA)。

#### 八点法

八点法是估计基础矩阵和本质矩阵的一种经典方法，适用于最小数量的8对匹配点。其基本步骤如下：

- 选择匹配点**：从图像中选取8对匹配点。
- 构建线性方程**：利用每对匹配点构建一个线性方程，最终形成一个 $8 \times 9$ 的方程组。
- 求解基础矩阵**：通过奇异值分解 (SVD) 求解方程组，得到基础矩阵。
- 约束调整**：调整基础矩阵的秩，使其满足秩为2的约束条件。

## 五点法

五点法是一种用于估计本质矩阵的高效方法，适用于最小数量的5对匹配点。其基本步骤如下：

- 选择匹配点**：从图像中选取5对匹配点。
- 构建多项式方程**：利用每对匹配点构建多项式方程组。
- 求解本质矩阵**：通过求解多项式方程组的根，得到本质矩阵。

## 光束平差法与非线性优化

光束平差法（Bundle Adjustment, BA）是一种非线性优化技术，用于在多视图重建中同时优化相机位姿和三维点坐标。其目标是通过最小化所有观测点的重投影误差，提高重建结果的精度。

### 光束平差法

光束平差法的基本步骤如下：

- 初始化**：利用线性方法（如八点法、五点法）初步估计相机位姿和三维点坐标。
- 误差定义**：定义重投影误差，即图像中的特征点坐标与由三维点投影得到的图像坐标之间的差异。
- 构建误差函数**：将所有观测点的重投影误差累加，构建误差函数。
- 最小化误差**：通过非线性优化算法（如Levenberg-Marquardt算法）最小化误差函数，调整相机位姿和三维点坐标。

### 非线性优化

光束平差法使用的非线性优化算法主要包括：

- Levenberg-Marquardt算法**：
  - 一种迭代优化算法，通过调整优化步长，在梯度下降法和牛顿法之间取得平衡。
  - 适用于处理参数较多、优化过程复杂的问题。
- 稀疏优化**：针对大规模问题（如包含上百幅图像和成千上万个三维点），光束平差法采用稀疏矩阵表示，利用稀疏线性代数技术提高计算效率。

### 实例：光束平差法的应用

以下是一个光束平差法应用实例，展示了如何在多视图重建中优化相机位姿和三维点坐标：

- 初始化**：
  - 使用八点法或五点法估计初始相机位姿和三维点坐标。
- 构建误差函数**：对于每个特征点，计算其在图像中的重投影误差：

$$e_{ij} = \|x_{ij} - P_i X_j\|$$

其中， $x_{ij}$ 是第*i*幅图像中第*j*个特征点的观测坐标， $P_i$ 是第*i*幅图像的投影矩阵， $X_j$ 是第*j*个三维点的坐标。

- 最小化误差**：使用Levenberg-Marquardt算法最小化所有重投影误差的总和：

$$\min \sum_{i,j} \|x_{ij} - P_i X_j\|^2$$

- 优化结果**：通过多次迭代，调整相机位姿和三维点坐标，使得重投影误差最小化，提高重建精度。

# 稠密立体视与视差图

稠密立体视 (Dense Stereo Vision) 是指通过计算图像中的每个像素点的视差来生成视差图，进而恢复场景的深度信息。视差图是立体视觉的重要输出之一，它表示图像中每个像素点的视差信息。以下是稠密立体视的计算与视差图生成的详细介绍。

## 稠密立体视的计算与视差图生成

稠密立体视的计算涉及到从双目图像对中计算每个像素点的视差，并生成视差图。这一过程通常包括以下几个步骤：

- 图像预处理**：对图像进行预处理，如去噪、增强对比度等，以提高匹配的准确性。
- 特征匹配与代价计算**：块匹配 (Block Matching)：将图像分成若干小块，通过滑动窗口的方法在另一幅图像中搜索匹配块。常用的匹配代价包括：

- 绝对差 (SAD, Sum of Absolute Differences)：

$$SAD = \sum_{(i,j) \in W} |I_1(i,j) - I_2(i+d,j)|$$

- 平方差 (SSD, Sum of Squared Differences)：

$$SSD = \sum_{(i,j) \in W} (I_1(i,j) - I_2(i+d,j))^2$$

- 归一化互相关 (NCC, Normalized Cross-Correlation)：

$$NCC = \frac{\sum_{(i,j) \in W} (I_1(i,j) - \bar{I}_1)(I_2(i+d,j) - \bar{I}_2)}{\sqrt{\sum_{(i,j) \in W} (I_1(i,j) - \bar{I}_1)^2 \sum_{(i,j) \in W} (I_2(i+d,j) - \bar{I}_2)^2}}$$

其中， $W$  为窗口， $I_1$  和  $I_2$  分别为左图和右图， $\bar{I}_1$  和  $\bar{I}_2$  为窗口内的均值。

- 视差计算与视差图生成**：对于每个像素点，通过滑动窗口计算视差代价，选择代价最小的视差值作为该像素点的视差。重复这一过程，生成整个图像的视差图。
- 后处理**：对生成的视差图进行后处理，如中值滤波、双边滤波等，以去除噪声，提高视差图的平滑度和准确性。

## 滤波器与模板匹配的实现

滤波器与模板匹配在稠密立体视计算中起到关键作用，通过匹配窗口内的像素值来计算匹配代价。以下是滤波器与模板匹配的实现细节。

### 滤波器

滤波器在图像处理中用于去噪和平滑，以提高匹配精度。常用的滤波器包括：

- 均值滤波 (Mean Filter)**：对图像进行均值滤波，可以去除高频噪声，使图像更加平滑。均值滤波器的定义为：

$$I'(i,j) = \frac{1}{|W|} \sum_{(k,l) \in W} I(i+k,j+l)$$

其中， $W$  为滤波窗口， $I$  为原始图像， $I'$  为滤波后的图像。

- 中值滤波 (Median Filter)**：中值滤波通过取窗口内像素值的中值，能够有效去除椒盐噪声。中值滤波器的定义为：

$$I'(i,j) = \text{median}\{I(i+k,j+l) | (k,l) \in W\}$$

3. **双边滤波 (Bilateral Filter)**：双边滤波不仅考虑空间距离，还考虑像素值差异，可以保留边缘信息。双边滤波器的定义为：

$$I'(i, j) = \frac{1}{W(i, j)} \sum_{(k, l) \in W} I(i + k, j + l) \cdot \exp\left(-\frac{(k^2 + l^2)}{2\sigma_s^2}\right) \cdot \exp\left(-\frac{(I(i + k, j + l) - I(i, j))^2}{2\sigma_r^2}\right)$$

其中， $W(i, j)$ 是归一化系数， $\sigma_s$ 和 $\sigma_r$ 分别控制空间和颜色相似度。

## 模板匹配

模板匹配是通过滑动窗口计算匹配代价的方法，用于寻找最佳匹配块。以下是几种常用的模板匹配代价计算方法：

1. **绝对差 (SAD, Sum of Absolute Differences)**：计算窗口内像素值的绝对差之和，代价较低的匹配块视为最佳匹配。

$$SAD = \sum_{(i, j) \in W} |I_1(i, j) - I_2(i + d, j)|$$

2. **平方差 (SSD, Sum of Squared Differences)**：计算窗口内像素值的平方差之和，代价较低的匹配块视为最佳匹配。

$$SSD = \sum_{(i, j) \in W} (I_1(i, j) - I_2(i + d, j))^2$$

3. **归一化互相关 (NCC, Normalized Cross-Correlation)**：计算窗口内像素值的归一化互相关，代价较低的匹配块视为最佳匹配。

$$NCC = \frac{\sum_{(i, j) \in W} (I_1(i, j) - \bar{I}_1)(I_2(i + d, j) - \bar{I}_2)}{\sqrt{\sum_{(i, j) \in W} (I_1(i, j) - \bar{I}_1)^2 \sum_{(i, j) \in W} (I_2(i + d, j) - \bar{I}_2)^2}}$$

## 从透视重构到仿射重构

从透视重构到仿射重构的过程是三维重建中的一个重要步骤。透视重构 (Projective Reconstruction) 恢复了场景的三维结构，但仍存在透视变换的不确定性。通过仿射重构 (Affine Reconstruction)，可以消除这一不确定性，进一步得到更准确的三维结构。以下是详细介绍。

### 透视重构的基本概念

透视重构是利用多个视图中的点对应关系，通过透视投影恢复场景的三维结构。透视重构通常是三维重建的初始步骤，通过计算相机的投影矩阵和场景点的三维坐标，建立起图像与三维世界之间的映射关系。

1. **投影矩阵**：投影矩阵  $PPP$  描述了从三维点到二维图像点的投影关系。对于一个三维点  $X = (X, Y, Z, 1)^T$ ，其在图像中的投影点  $x = (u, v, 1)^T$  可以表示为： $x = PX$  其中， $PPP$  是  $3 \times 4$  的投影矩阵。

2. **透视重构的基本步骤**：

- **匹配点收集**：在多幅图像中检测和匹配特征点，得到对应点的集合。
- **估计基础矩阵**：使用八点法或其他方法估计基础矩阵  $F$ ，从而确定两幅图像之间的几何关系。
- **计算投影矩阵**：从基础矩阵  $F$  推导相机的投影矩阵  $P$  和  $P'$ 。
- **三角测量**：利用投影矩阵  $P$  和  $P'$ ，通过三角测量方法计算三维点的坐标。

3. **透视重构的不确定性**：透视重构中的三维点和投影矩阵存在一个不可确定的透视变换  $H$ 。如果  $X$  是透视重构中的三维点， $PP$  是投影矩阵，那么对于任意的非奇异  $4 \times 4$  矩阵  $H$ ，变换后的三维点  $X' = HX$  和变换后的投影矩阵  $P' = PH^{-1}$  也能满足投影关系  $x = P'X'$ 。

## 仿射重构与度量重构

仿射重构 (Affine Reconstruction) 通过消除透视变换的不确定性, 使重建的三维结构具有仿射性质, 即保持平行和比例关系。度量重构 (Metric Reconstruction) 进一步恢复场景的真实比例和角度关系。

- 仿射重构的基本概念:** 仿射重构是将透视重构中的三维点和投影矩阵进行变换, 使得重建结果满足仿射几何性质。仿射变换保持了平行线的平行性和比例关系, 但不保留角度和距离。
- 从透视重构到仿射重构:** 仿射重构通过确定无穷远平面  $\pi_\infty$  来实现。无穷远平面上的点在仿射变换下保持不变。通过将透视重构结果与无穷远平面对齐, 可以消除透视变换的不确定性。
- 度量重构的基本概念:** 度量重构在仿射重构的基础上进一步恢复场景的真实比例和角度关系。度量重构需要知道相机的内参或通过已知的几何约束 (如正交关系) 进行标定。

## 无穷单应与仿射重构的关系

无穷单应 (Infinite Homography) 是将透视重构变换为仿射重构的关键工具。通过无穷单应矩阵, 可以将无穷远平面上的点映射到图像平面, 从而实现仿射重构。

- 无穷远平面与无穷单应:** 无穷远平面  $\pi_\infty$  包含所有平行线的交点。在透视投影下, 这些点在无穷远处。无穷单应  $H_\infty$  是将无穷远平面的点映射到图像平面的单应矩阵。
- 仿射重构中的无穷单应:** 在仿射重构过程中, 选择合适的无穷单应矩阵  $H_\infty$ , 将透视重构结果与无穷远平面对齐。假设透视重构中的投影矩阵为  $P$  和  $P'$ , 则通过无穷单应  $H_\infty$  变换后的投影矩阵可以表示为:  $P_{affine} = PH_\infty, P'_{affine} = P'H_\infty$
- 仿射重构步骤:**
  - 无穷远平面确定:** 通过几何约束 (如已知的平行线) 确定无穷远平面。
  - 计算无穷单应:** 根据无穷远平面计算无穷单应矩阵。
  - 变换投影矩阵:** 使用无穷单应矩阵变换透视重构中的投影矩阵和三维点, 得到仿射重构结果。

## 摄像机运动与重构

摄像机运动与重构在三维重建中起着至关重要的作用。不同的摄像机运动模式对重构的精度和复杂度有不同的影响。以下详细介绍摄像机运动模式对重构的影响、基于摄像机运动的仿射歧义消除以及从仿射重构到相似重构的转换。

### 摄像机运动模式对重构的影响

摄像机运动模式对三维重构的影响主要体现在相机的运动方式会影响点的投影位置和重建的精度。常见的摄像机运动模式包括平移、旋转和平移+旋转。

- 纯平移运动 (Pure Translation) :**
  - 当相机进行纯平移运动时, 相机内部参数不变, 且视图之间的基础矩阵具有特殊形式。平移运动通常用于恢复场景的相对深度和结构, 但难以精确恢复绝对比例。
  - 特点:
    - 基线方向上的运动产生视差, 深度估计与视差成反比。
    - 对于平移运动, 图像中的平行线在无穷远处相交, 简化了无穷远平面的确定。
  - 影响: 可以通过找到匹配点对并估计无穷远平面, 消除仿射歧义。
- 纯旋转运动 (Pure Rotation) :**
  - 当相机进行纯旋转运动时, 图像中的点只是围绕相机中心旋转, 而不产生视差。纯旋转运动不能直接用于深度估计, 但可以用于校正图像失真。
  - 特点:

- 没有基线长度，无法直接计算深度。
- 适用于图像对齐和视图变换。
- 影响：主要用于图像配准，而非深度重建。

### 3. 平移+旋转 (Translation + Rotation) :

- 当相机同时进行平移和旋转运动时，可以通过八点法或五点法估计基础矩阵或本质矩阵，并进行三维重建。
- 特点：
  - 复杂的运动模式，包含平移和旋转分量。
  - 需要更多的匹配点来提高重建精度。
- 影响：
  - 通过全局优化（如光束平差法）提高重建精度，适用于复杂场景的三维重建。

## 基于摄像机运动的仿射歧义消除

仿射歧义 (Affine Ambiguity) 是指在仿射重构过程中，三维点和投影矩阵存在一个不可确定的仿射变换。基于摄像机运动，可以消除仿射歧义，使得重建结果更加精确。

### 1. 消除仿射歧义的基本方法：

- **确定无穷远平面**：通过摄像机运动，特别是平移运动，确定无穷远平面上的点。
- **计算无穷单应**：使用无穷远平面上的点计算无穷单应矩阵，将透视重构变换为仿射重构。
- **变换投影矩阵和三维点**：使用无穷单应矩阵对投影矩阵和三维点进行变换，消除仿射歧义。

2. **实例**：假设有两幅图像，其投影矩阵分别为  $P$  和  $P'$ 。通过无穷远平面确定无穷单应矩阵  $H_\infty$ ，可以将投影矩阵变换为：

$$\begin{aligned} P_{affine} &= PH_\infty \\ P'_{affine} &= P'H_\infty \end{aligned}$$

## 从仿射重构到相似重构的转换

从仿射重构到相似重构的过程是通过引入度量信息，进一步消除仿射变换的不确定性，使得重建结果具有真实的比例和角度关系。

### 1. 相似重构的基本概念：

- 相似重构在仿射重构的基础上，恢复场景的比例和角度关系。相似变换保持了形状的相似性，但允许整体缩放、旋转和平移。

### 2. 相似重构的实现方法：

- **确定绝对二次曲面 (Absolute Quadric) :**
  - 绝对二次曲面  $\Omega$  是一个二次曲面，通过它可以恢复相机的内参和外参。
  - 在仿射重构的基础上，利用已知的度量信息（如正交约束、已知长度等），确定绝对二次曲面。
- **计算度量单应**：度量单应  $\mathcal{H}$  是将仿射重构变换为相似重构的单应矩阵。通过度量单应，可以将仿射重构的结果变换为度量重构。
- **变换投影矩阵和三维点**：
  - 使用度量单应  $\mathcal{H}$  对投影矩阵和三维点进行变换，得到相似重构结果。
  - 通过度量单应变换后的投影矩阵和三维点为：

$$P_{metric} = P_{affine} \mathcal{H}$$

$$P'_{metric} = P'_{affine} \mathcal{H}$$